




DWH

Data Vault - 1



Проверить, идет ли запись

Меня хорошо видно && слышно?



Правила вебинара



Активно
участвуем



Off-topic обсуждаем
в telegram **#dwh-2024-06**



Задаем вопрос
в чат или голосом



Вопросы вижу в чате,
могу ответить не сразу

Условные обозначения



Индивидуально



Время, необходимое
на активность



Пишем в чат



Говорим голосом




Документ



Ответьте себе или
задайте вопрос

Маршрут вебинара



Знакомство

Модель Data Vault

Архитектурные паттерны

Пример модели DV

Рефлексия

Цели вебинара

К концу занятия вы сможете

1. Погрузиться в подход к организации детального слоя Data Vault 2.0
2. Рассмотреть пример построения DWH на DV 2.0.

Тема вебинара

Data Vault - 1



Андрей Тюрин

DWH Analyst

- 4 года опыта Аналитиком хранилищ данных
- Сейчас работаю в экосистеме услуг для бизнеса
- Ранее : на проектах крупных банков

[LinkedIn](#)



Смысл

Зачем вам это уметь

1. Научиться применять подход Data Vault для моделирования детального слоя DWH
-

Требования при проектировании DWH

Требования к самому хранилищу:

- Гетерогенность источников
- Поддержка историчности
- Гибкость модели данных
- Скорость обновления
- Устойчивость к объёму

Типовые кейсы:

- Добавление новых данных (источники) в существующую модель
- Отработка изменений на источниках
- Создание пользовательских представлений и их сопровождение
- ...

Краткий экскурс в Data Vault

Data Vault — одна из моделей хранилища данных (Data Warehouse). Структура Data Vault предусматривает длительное хранение больших объемов разнородной информации. Модель Data Vault содержит временные отметки размещения данных и позволяет проследить изменение хранимой информации во времени. Поэтому этот вид хранилища используется, например, при работе систем учета взаимоотношений с клиентами (CRM), в системах анализа и управления технологическими процессами, а также в аудите.

История появления Data Vault

Модель Data Vault была описана создателем, **Дэном Линстедтом**, в конце 1990-х и представлена общественности в 2000 году. Дэн Линстедт в пяти статьях разобрал общую концепцию модели хранилища, правила создания и соединения основных компонентов (таблиц), привел примеры использования выборки информации для обработки запросов пользователей, а также методы загрузки данных в хранилище.

В 2013 году появилась концепция Data Vault 2.0, в которой разобрано использование хранилища в NoSQL СУБД, при работе с неструктурированной информацией и большими данными (Big Data), описаны методы бесшовной интеграции и разобраны лучшие практики внедрения Data Vault.

Отличия Data Vault от других типов хранилищ данных

Основное назначение любого вида Data Warehouse — надежное хранение больших объемов разнородной информации. При этом прочие параметры, такие как скорость доступа, достоверность или избыточность информации, являются вторичными.

С учетом требований к хранимым данным выделяют два основных типа хранилищ: хранилища в третьей нормальной форме (3NF) и хранилища с измерениями (типа «Звезда» или «Снежинка»).


Хранилища с измерениями

Хранилища с измерениями строят по схемам «звезда» или «снежинка».


Данные расположены в узлах хранилища в виде таблиц фактов.

Связывающие таблицы фактов лучи также являются отдельными таблицами и называются таблицами измерений. Отличие подтипа «снежинка» от подтипа «звезда» — в наличии цепочек из таблиц измерений. Благодаря этому каждую отдельную таблицу измерений можно привести к третьей нормальной форме (в модели «звезда» таблицы измерений не нормализованы).

Пример структуры хранилища по схеме «звезда»




Пример структуры хранилища по схеме «снежинка»



Характеристика	3NF	Звезда / Снежинка	Data Vault
Нормализация таблиц	Обязательная	Не обязательная	Не обязательная
Структура хранилища	Простая	Сложная	Сложная
Объем хранимой информации	Средний или малый	Большой	Большой
Скорость доступа к информации	Средняя	Высокая	Высокая
Затраты на разработку и реорганизацию	Низкие	Высокие	Средние

Data Vault и 3NF

Несмотря на то, что Data Vault является разновидностью хранилища с измерениями, для которых не обязательна нормализация таблиц, этот тип хранилища может быть сконструирован как для NoSQL, так и для реляционных СУБД. Благодаря гибкой структуре вспомогательных таблиц Сателлитов, отдельные ветки или даже всю базу данных можно привести к классической третьей нормальной форме (3NF).



Типы сущностей в DV2.0



HUB

Хранит связь бизнес-ключа с хэш-ключом.

- И метаданные.
- Всё. Никаких свойств объекта не хранится.



LINK

Используется для связи между хабами

И ТОЛЬКО ХАБАМИ

- Хранит ≥ 2 хэш-ключей хабов и метаданные.
- Больше ничего.
Интертемпоральности у линков тоже нет.




SATELLITE


Это весь контекст.

- Хранит все свойства, отношения и прочее.
- Отражает изменения во времени.
- Всегда ссылается только на 1 ХАБ или Линк. Т.е. содержит ссылку на РК этих сущностей

Разные модели ИС




Единая модель




Пример модели DV 2.0


Пример ЛМД




Компания: HUB + SATELLITE




Предприятие: HUB + SATELLITE



Связь К-П: LINK



Связь К-П: LINK



Структура таблиц: что внутри?



HUB Company

HK_Company (PK)

LoadDate
RecordSource

INN
KPP



SAT CompanyProps

HK_Sat_Company (PK)
HK_Company (FK)

LoadDate
RecordSource

LoadEndDate
RecordHash
DirectorName
PhoneNumber



LINK CompanyFacility

HK_LINK (PK)

LoadDate
RecordSource

HK_Company (FK)
HK_Facility (FK)

Всё ли понятно?



HUB

Хранит связь бизнес-ключа с хэш-ключом.

- И метаданные.
- Всё. Никаких свойств объекта не хранится.



LINK

Используется для связи между хабами

И ТОЛЬКО ХАБАМИ

- Хранит ≥ 2 хэш-ключей хабов и метаданные.
- Больше ничего.
Интертемпоральности у линков тоже нет.



SATELLITE

Это весь контекст.

- Хранит все свойства, отношения и прочее.
- Отражает изменения во времени.
- Всегда ссылается только на 1 ХАБ или Линк. Т.е. содержит ссылку на РК этих сущностей

Архитектурные паттерны Data Vault



Почему Hash-сумма для ключа?

Hash в основе DV 2.0

- Классический суррогатный ключ - **sequence** (монотонная последовательность)
- Исторически сложности с sequence в **Hadoop**
- DV 2.0 вводит хеш-сумму в качестве ключа
- Хеш будет консистентным между **Data Lake** <-> **DWH**
- Одна колонка, один тип



Как отследить изменения атрибутивного состава сущности?

Метод “в лоб”



if A1 != A2 or (A1 is null or A2 is null and not (A1 is null and A2 is null))

Hash Difference

md5(concatenated column values)



If table1_hashdiff != table2_hashdiffs

Когда появляется >1 SATELLITES?

- Несколько источников с разными атрибутами
- Разная скорость изменения (часто/редко)
- Разделение на группы как требование проектирования
- Результат расширения атрибутного состава (гибкость)

Несколько Satellites

HUB_EMPLOYEE		
HUB_EMPLOYEE_KEY	char(32)	PK
PassportID	number(6)	BK
HUB_Load_DTS	date	
HUB_Rec_SRC	varchar(12)	



SAT_EMPLOYEE_NAME		
HUB_EMPLOYEE_KEY	char(32)	FK
EMPLOYEE_NAME_HASHDIFF	char(32)	PK
SAT_Load_DTS	date	
SAT_Rec_SRC	varchar(12)	
FIRST_NAME	varchar(25)	N
LAST_NAME	varchar(25)	N
HIRE_DATE	date	N



SAT_EMPLOYEE_ADDRESS		
HUB_EMPLOYEE_KEY	char(32)	FK
EMPLOYEE_ADDRESS_HASHDIFF	char(32)	PK
SAT_Load_DTS	date	
SAT_Rec_SRC	varchar(12)	
ADDRESS1	varchar(25)	
ADDRESS2	varchar(25)	N
CITY	varchar(25)	
COUNTRY	varchar(25)	N




Это ещё не всё

- Same-as-links
- Computed Satellites
- Master Data Management
- Reference tables
- Data Quality

<https://datajoinery.io/datajoinerys-data-vault-key-concepts/>


DV не исключает star / snowflake !

Presentation Layer




Views can be used to
expose a star schema


DV не исключает star / snowflake !




DV не исключает star / snowflake !



DV не исключает star / snowflake !




DV не исключает star / snowflake !



DV не исключает star / snowflake !

Customer Ensemble


Two Sources



Практика

Представлена ER-модель части операционной базы данных. Для построения DWH необходимы четыре таблицы операционной системы:


- Person
- Manager
- Department
- Company



Практика

DWH будет состоять из 3-х слоев:

- stage
- intermediate
- marts



Практика

Staging area (STG) – копия данных из системы-источника. На этом этапе необходимые для анализа данные собираются из операционной базы данных без изменений.

Практика

Dimensional Data Store (DDS) – на этом этапе над данными в STG совершаются трансформации (JOIN, добавление столбцов и т.д.), необходимые перед загрузкой в DWH.

В рамках Data Vault необходимо произвести следующие операции:

- Для каждой таблицы выбрать бизнес-ключ
- Создать хэш бизнес-ключа каждой таблицы
- В каждую таблицу добавить технические данные (source, load_ts)
- Создать таблицы-связи (link)
- Создать таблицы-хабы
- Создать таблицы-сателлиты

Практика

Common Data Mart (CDM) – данные, готовые для визуализации. (на основе витрин выбираем таблицы в источниках и сами источники, которые будут нужны)

Необходимо реализовать следующие метрики:

- Количество менеджеров в каждом департаменте
- Количество сотрудников (не менеджеров) в каждом департаменте

Что изучить?

Список материалов для изучения

1. [Серия из 4-х статей от Kent Graziano \(Snowflake\)](#)
2. [Building a Scalable Data Warehouse with Data Vault 2.0 dbtvault docs](#)
3. [Pentaho® Kettle Solutions: Chapter 19. Data Vault Management](#)

Рефлексия

Рефлексия



С какими впечатлениями уходите с вебинара?



Как будете применять на практике то, что узнали на вебинаре?

Следующий вебинар



25 ноября 2024

Data Vault - 2



Ссылка на вебинар
будет в ЛК за 15 минут



Материалы
к занятию в ЛК —
можно изучать



Обязательный
материал обозначен
красной лентой



**Заполните,
пожалуйста, опрос о
занятии
по ссылке в чате**