



Data Engineer



Проверить, идет ли запись

**Меня хорошо видно
&& слышно?**



Тема вебинара

Apache Airflow. Введение в автоматизацию пайплайнов и оркестрацию



Алексей Железной

Data Engineer

- 4 года опыта Инженером данных/аналитиком (Python, Airflow, Clickhouse, Greenplum)
- 2 года опыта преподавания в OTUS (курсы DWH Analyst/DE/PostgreSQL Cloud)

[LinkedIn](#)

Правила вебинара



Активно
участвуем



Задаем вопрос
в чат или голосом



Вопросы вижу в чате,
могу ответить не сразу

Условные обозначения



Индивидуально



Время, необходимое
на активность



Пишем в чат



Говорим голосом




Документ



Ответьте себе или
задайте вопрос

Маршрут вебинара



Оркестрация, cron

Знакомство с Apache Airflow

Развертывание

Цели вебинара

В ходе занятия вы

1. Узнаете о том, какие задачи решают оркестраторы
2. Познакомитесь с составными частями Airflow
3. Проведете установку инструмента



Смысл

Зачем вам это уметь

1. Оркестрация сегодня – общепринятый подход и стандарт в работе Data Engineer
2. Много источников данных и хранилищ => необходимость автоматизировать процессы перекачки, трансформации и сохранения
3. Грамотный и быстрый подбор релевантного инструмента = залог успешной работы без сорванных дедлайнов + довольные бизнес-заказчики


Оркестрация

cron

Используется для периодического выполнения заданий в определённое время.

Цели:

- автоматизация рутинных задач
- периодический запуск процессов без участия человека



```
maverick@maverick-Inspiron-5548: ~  
GNU nano 2.5.3 File: /tmp/crontab.7jJqID/crontab  
# Edit this file to introduce tasks to be run by cron.  
#  
# Each task to run has to be defined through a single line  
# indicating with different fields when the task will be run  
# and what command to run for the task  
#  
# To define the time you can provide concrete values for  
# minute (m), hour (h), day of month (dom), month (mon),  
# and day of week (dow) or use '*' in these fields (for 'any').#  
# Notice that tasks will be started based on the cron's system  
# daemon's notion of time and timezones.  
#  
# Output of the crontab jobs (including errors) is sent through  
# email to the user the crontab file belongs to (unless redirected).  
#  
# For example, you can run a backup of all your user accounts  
# at 5 a.m every week with:  
# 0 5 * * 1 tar -zcf /var/backups/home.tgz /home/  
#  
[ Read 22 lines  
^G Get Help ^O Write Out ^M Where Is ^K Cut Text ^J Justify ^C Cur Pos  
^X Exit ^R Read File ^A Replace ^U Uncut Text ^T To Spell ^_ Go To Line
```

cron

Плюсы:

- Просто
- <https://crontab.guru/>
- Есть по умолчанию на вашем Mac/Linux сервере

Минусы:

- Слишком просто
- Нет ui
- Нет нормального логирования
- Нельзя создавать связи между задачами

Оркестрация сейчас

Почему это удобно?

- Управление через GUI
- 1 веб-портал для всех процессов, всех серверов
- Можно делать связи между задачами (и даже очень сложные)
- Любая логика
- Интеграция с Slack, Telegram и т.д., которую уже кто-то сделал
- Alerts & SLAs



Вопросы?



Ставим "+",
если вопросы есть



Ставим "-",
если вопросов нет

Airflow. Основные моменты

Основные понятия

DAG - Directed Acyclic Graph:

- **DIRECTED** — **направленный**. В общем, если существует несколько задач (тасков), каждая из них должна иметь по крайней мере одну материнскую (предыдущую) или дочернюю (последующую) задачу.
- **ACYCLIC** — **ациклический**. Ни одна задача не может создавать данные, которые будут ссылаться на самих себя.
- **GRAPH** — **граф**. В математике граф представляет собой конечный набор узлов с вершинами, соединяющими узлы.

Основные понятия

- **Workflow** – последовательность шагов для выполнения Data Engineering задачи
- **Task** – одна задача (скачать файл/загрузить csv на s3-хранилище/послать sql и забрать результат)
- **Operator** – тип задачи
- **Task instance** – конкретный запуск задачи (в определенный период)
- **DAG run** – конкретный запуск DAG


Как выполняется работа в Airflow

- **Операторы** содержат логику того, как данные обрабатываются в конвейере
- **Задача (task, task)** — это экземпляр Оператора
- Задачи — это узлы в DAG
- **DAG run** — это однократное конкретное выполнение DAG

Архитектура Airflow

- Web Server — отвечает за пользовательский интерфейс
- Metadata DB (база метаданных)
- Scheduler (планировщик) — служба, отвечающая за планирование в Airflow
- Worker (рабочий) — отдельный процесс, в котором выполняются задачи
- Executor (исполнитель) — механизм, с помощью которого запускаются экземпляры задач.

Архитектура Airflow



Вопросы?



Ставим “+”,
если вопросы есть



Ставим “-”,
если вопросов нет

Принцип работы

Операторы

Это классы, которые содержат логику выполнения единичной работы.

Примеры:

- BashOperator
- PythonOperator

Хуки (hooks)

- Охватывают API-интерфейсы и предоставляют методы для взаимодействия с различными внешними системами.
- Наследуются от класса класса BaseHook, который содержит логику для настройки внешнего соединения с заданным идентификатором соединения


Sensors

Это просто Operator, который ждет выполнения определенного условия. Используется, когда:

- непонятно, когда наступит целевое событие
- нельзя сразу “падать”
- нужно добавить повторяющееся событие

Branching

- Добавляет Airflow логику "с условиями"
- Использует BranchPythonOperator



```
from airflow.models import DAG
from datetime import datetime
from airflow.operators.python_operator import BranchPythonOperator

default_arguments = {
    'owner': 'user',
    'email': 'user@mail.com',
    'start_date': datetime(2021, 1, 21)
}
etl_dag = DAG('prod_workflow', default_args=default_arguments)

def branch(**kwargs):
    if int(kwargs['ds_nodash']) % 2 == 0: # ds_nodash - специальный template
        return 'even_day_task'
    else:
        return 'odd_day_task'

branch_task = BranchPythonOperator(task_id='branch_task', dag=etl_dag,
                                   provide_context=True,
                                   python_callable=branch)

start_task >> branch_task >> even_day_task >> even_day_task2
branch_task >> odd_day_task >> odd_day_task2
```


Способы запуска DAGs

- По расписанию (@hourly/@weekly/20 * * * * и тд)
- Через GUI
- Через CLI
- Используя Sensors

Вопросы?



Ставим "+",
если вопросы есть



Ставим "-",
если вопросов нет



LIVE

Вопросы?



Ставим “+”,
если вопросы есть



Ставим “-”,
если вопросов нет

Список материалов для изучения

1. [Инструкция по установке](#)
2. [Документация Airflow](#)
3. [Интерактивная справка по cron](#)
4. [Сравнение Luigi и Airflow](#)
5. [Операторы Airflow](#)

Рефлексия

Цели вебинара

В ходе занятия вы

1. Узнаете о том, какие задачи решают оркестраторы
2. Познакомитесь с составными частями Airflow
3. Проведете установку инструмента

Рефлексия



С какими впечатлениями уходите с вебинара?



Как будете применять на практике то, что узнали на вебинаре?

**Заполните, пожалуйста,
опрос о занятии
по ссылке в чате**

Спасибо за внимание!

Приходите на следующие вебинары



Алексей Железной

Data Engineer

[LinkedIn](#)