

A decorative graphic in the top-left corner consisting of a grid of small squares in red, orange, and yellow, arranged in a pattern that tapers to the right.

Data Warehouse Analyst



Проверить, идет ли запись

Меня хорошо видно && слышно?

Ставим "+", если все хорошо
"-", если есть проблемы

Тема вебинара

Data Quality (Качество данных)



Водовозова Татьяна

Руководитель направления аналитики DWH

Об опыте:

- участвовала в проектах развития хранилищ данных,
- построение хранилищ с нуля,
- миграция данных
- [ментор](#)

Правила вебинара



Активно
участвуем



Off-topic обсуждаем
в Telegram @OTUS DWH-2025-04



Задаем вопрос
в чат или ГОЛОСОМ



Вопросы вижу в чате,
могу ответить не сразу

Условные обозначения



Индивидуально



Время, необходимое
на активность



Пишем в чат



Говорим голосом




Документ



Ответьте себе или
задайте вопрос

Карта курса



Цели вебинара

К концу занятия вы сможете

1. Понять значение Data Quality в работе с данными
2. Разобраться с циклом работы Data Quality
3. Научиться определять и строить метрики качества данных
4. Узнать о способах мониторинга
5. Разобраться с процессом обработки ошибок



Смысл

Зачем вам это уметь

1. Обеспечить консистентность данных
2. Своевременно реагировать на отклонения
3. Упростить поддержку и развитие DWH

Качество данных

Что такое качество данных

Что такое качество данных

- Оценка пригодности данных для заданных целей и задач
- Внесение изменений, необходимых для поддержания качества данных

Зачем нужно управлять качеством данных

Мусор на входе = Мусор на выходе $f(\text{🗑}) = \text{🗑}$




DO WE TRUST THIS DATA?

На что влияет качество данных

- Доверие используемым данным
- Качество управленческих решений
- Удовлетворенность клиентов
- Эффективный маркетинг
- Снижение затрат / повышение маржинальности
- Регуляторные и репутационные риски

Процесс управления качеством данных



Планирование

Какие задачи хотим решить?

- Базовые ожидания: Not Null, Unique, Foreign Key
- Ожидания выполнения бизнес-правил
- Данные источников приходят вовремя
- Витрины содержат актуальные данные
- *Витрины строятся в рамках SLA (Performance)
- *Изменения не ломают DWH
- *Регулярные кросс-сверки Источник <-> Приемник

Критерии оценки качества данных

- Технические проверки
- Бизнес проверки

Критерии оценки качества данных

- Completeness: пропуски в данных
- Uniqueness: наличие дубликатов
- Referential integrity: ссылочная целостность
- Domain integrity: соответствие правилам
- Timeliness: актуальность на момент времени

Вопросы?



Ставим “+”,
если вопросы есть



Ставим “-”,
если вопросов нет

Реализация

Completeness

- Полнота данных
- Заполнено всё то, что должно быть заполнено

Table 1

Name	Address	Phone
Андрей	Нагатинская 10	79159999999
Артур		79169999999

Completeness - как проверить в SQL

```
select count(*) as client_adress_null  
from table1  
where address is null
```

Uniqueness

- Уникальность
- Отсутствие дублей по ключу

TransactionID	ClientID	Status
1	123	Success
1	123	Success
2	234	Failed
2	234	Success

Uniqueness - как проверить в SQL

```
select count(*) as transaction_duplicate  
from table2  
where status = "Success"  
group by trasaction_id  
having count(*) > 1
```

Referential integrity

- Ссылочная целостность
- Справочники и связи

Date	ClientID	ProductID	Amount
2023-01-01	123	1	1000
2023-01-01	123	2	50000

ProductID	ProductName	ProductPrice
1	Арахис	100
9999	Не определено	



Referential integrity - как проверить в SQL?

```
select count(s.*) as sale_product_null
from sale as s
left join product p
on s.productid = p.productid
where p.productid is null
```

Domain integrity

- Целостность по значениям

TransactionID	ClientID	Status
1	123	Success
1	123	Success
2	234	Failed



Domain integrity - как проверить в SQL?

```
with transaction_status as (  
    select distinct status  
    from table1  
)  
select count(*)  
from transaction_status  
where status not in ("Success", "Failed")
```

Timeliness/Freshness - актуальность

- Своевременно получаем данные из источников
- Можем сказать, на какое время актуальны данные

Timeliness/Freshness - как проверить в SQL?

```
with date_value as (  
    select max(created_at) as max_created_at, getdate() as snapshotted_at  
    from table1  
)  
select datediff(hh, max_created_at, snapshotted_at)  
from date_value
```

Бизнес правила

- Равенство сумм в источнике и витринах
- Баланс: дебет и кредит
- Один департамент – один начальник
- Одна акция по продукту в в одном периоде

Вопросы?



Ставим “+”,
если вопросы есть



Ставим “-”,
если вопросов нет



Внедрение

Тесты схемы - Яндекс.Директ

```
version: 2
```

```
models:
```

```
- name: stg_yd_campaigns
  tests: &direct_defaults
    - not_empty:
        severity: warn
    - not_null:
        column_name: id
    - unique:
        column_name: id

- name: stg_yd_adgroups
  tests: *direct_defaults

- name: stg_yd_ads
  tests: *direct_defaults

- name: stg_yd_sitelinks
  tests:
    - not_empty:
        severity: warn
    - not_null:
        column_name: id
    - unique:
        column_name: id
    - relationships:
        to: ref('stg_yd_ads')
        column_name: ads_id
        field: id
```



Еще больше тестов схемы

- Generic Tests
 - [equal_rowcount \(source\)](#)
 - [fewer_rows_than \(source\)](#)
 - [equality \(source\)](#)
 - [expression_is_true \(source\)](#)
 - [recency \(source\)](#)
 - [at_least_one \(source\)](#)
 - [not_constant \(source\)](#)
 - [not_empty_string \(source\)](#)
 - [cardinality_equality \(source\)](#)
 - [not_null_proportion \(source\)](#)
 - [not_accepted_values \(source\)](#)
 - [relationships_where \(source\)](#)
 - [mutually_exclusive_ranges \(source\)](#)
 - [sequential_values \(source\)](#)
 - [unique_combination_of_columns \(source\)](#)
 - [accepted_range \(source\)](#)
 - [Grouping in tests](#)

Пример своего теста

13 lines (10 sloc) | 324 Bytes

```
1 -- NON_EMPTY
2 {% macro test_not_empty(model, column_name) %}
3   {{ return(adapter.dispatch('test_not_empty', 'mybi_dbt_core')(model, column_name)) }}
4 {% endmacro %}
5
6 {% macro default__test_not_empty(model, column_name) %}
7
8   select
9     count(1) as row_count
10   from {{ model }}
11   having count(1) = 0
12
13 {% endmacro %}
```

```
5  ✓ | - name: stg_ym_sessions_facts
6  ✓ |   tests:
7  ✓ |     - not_empty:
8    |       severity: warn
```

Регулярный запуск тестов

Run Steps

✓	Clone Git Repository SUCCESS - 00:00:00	SHOW LOGS +
✓	Create Profile from Connection Wheely Redshift SUCCESS - 00:00:00	SHOW LOGS +
✓	Invoke dbt with `dbt deps` SUCCESS - 00:00:03	SHOW LOGS +
✓	Invoke dbt with `dbt test --schema --exclude f_chauffeurs_sessions_corrected` SUCCESS - 00:09:31	SHOW LOGS +
✓	Invoke dbt with `dbt test --data` SUCCESS - 00:00:29	SHOW LOGS +



SLA загрузок в хранилище данных

```
9  ✓ freshness:
10    warn_after: {count: 12, period: hour}
11    error_after: {count: 24, period: hour}
12    loaded_at_field: created_at
```

SLA загрузок в хранилище данных

Data Sources

Warning

SOME DATA SOURCES REQUIRE ATTENTION

39

OK

1

WARNING

0

STALE

an hour ago

LAST SNAPSHOT

PROD - SOURCE FRESHNESS >

JOB

Run #16011012 >

RUN

SOURCE	LOADER / LOADED	LAST SNAPSHOT	STATUS
> app_documents_prod (1)	Hevo	an hour ago	OK
> communication_prod (4)	Hevo	an hour ago	OK
> dq (10)	Airflow		UNTRACKED
> external (2)	S3	an hour ago	OK
> financial_service (6)	Hevo	an hour ago	OK
> flights_prod (2)	Hevo	an hour ago	OK
> gs (5)	Hevo		UNTRACKED
> manual_load (7)	Manual		UNTRACKED
> marketing_external_api (3)	analytics_etl (ECS)	an hour ago	WARNING ●
> marketing_hevo (2)	hevo		UNTRACKED

Great Expectation

```
bash

Would you like to profile 'data_dir'? [Y/n]:
Profiling 'data_dir' with 'BasicDatasetProfiler'
Profiling all 1 data assets from generator default
  Profiling 'form_submissions'...
    Preparing column 1 of 6: id
    Preparing column 2 of 6: first_name
    Preparing column 3 of 6: last_name
    Preparing column 4 of 6: email
    Preparing column 5 of 6: gender
    Preparing column 6 of 6: ip_address
  41 expectation(s) included in expectation_suite.
  Profiled 6 columns using 1000 rows from form_submissions (0.276 sec)

  Profiled 1 of 1 named data assets, with 1000 total rows and 6 columns in 0.2
  8 seconds.
  Generated, evaluated, and stored 41 Expectations during profiling. Please re
  view results using data-docs.

Data Docs

Great Expectations is building Data Docs from the data you just profiled!
Building Data Docs...
```

The screenshot shows a web browser displaying the Data Docs interface. The left sidebar contains a navigation menu with options: Overview, Name, Dates associated with name, Type of name (highlighted), Role, Other names, BI record ID, Type of resource, Content type, Material type, SRS number, Archival Resource Key, ISBN, Title, Variant titles, and Series title. The main content area displays details for the 'annual_tickses_files' asset. It shows a 'Role' section with 'Type: float'. Below this is a 'Properties' table with the following data:

Property	Value
Distinct (n)	0
Distinct (%)	—
Missing (n)	43
Missing (%)	100.0%

Below the table is an 'Other names' section with 'Type: string'. At the bottom, there is a 'Properties' section with the following data:

Property	Value
Distinct (n)	11
Distinct (%)	25.6%
Missing (n)	0
Missing (%)	—

At the bottom of the page, there is a 'Data Docs' link and a message: 'Great Expectations is building Data Docs from the data you just profiled! Building Data Docs...'

Тесты в рамках PR (Continuous Integration)



kzzzr approved these changes 4 days ago

[View changes](#)



GalinaMay merged commit `d10dd42` into `master` 1 hour ago

[Hide details](#)

[Revert](#)

2 checks passed



dbt Cloud dbt Cloud run success

[Details](#)



task-list-completed 6 / 6 tasks completed

[Details](#)



GalinaMay deleted the `fix-disputes-and-transactions-join` branch 1 hour ago

[Restore branch](#)



Вопросы?



Ставим "+",
если вопросы есть



Ставим "-",
если вопросов нет

Мониторинг

Логирование всех расчетов

```
+pre-hook: "{{ logging.log_model_start_event() }}"  
+post-hook: "{{ logging.log_model_end_event() }}"
```

Идентифицируем узкие места

Monitoring

dbt Audit 

Update 

Deployment Completed Date

Target *

Is Full Refresh (Yes / No)

Schema

Model

Last 7 Days

prod

Yes

No


Is any value

Is any value



dbt Deployment duration



dbt Deployments



Самые длительные и проблемные витрины



Кросс-проверки Источник<->Приёмник

Monitoring

Data Quality 

1m ago   

Status

is mismatch or missing in source

Source Relation

is any value

Target Relation

is any value

Source Attribute

is any value

Target Attribute

is any value

123

Warnings

8h ago

Last checked

Measure	users	user_promo_codes	orders	drivers	companies	app_installs
1 Warnings	19	38	35	7	2	7
2 Hours ago	8h	8h	8h	8h	8h	8h

Data Quality Summary

Table-level matrix

Status	Target Relation	mismatch	missing in source
Row Count	Row Count	Row Count	Row Count
1 users	19	0	0
2 user_promo_codes	35	3	0
3 orders	35	0	0
4 drivers	7	0	0
5 companies	2	0	0
6 app_installs	7	0	0

Attribute Summary

Drill-down to atomic rows available (Click on Row Count)

Target Relation	Target Attribute	Status	Row Count
1 users	updated_at	mismatch	18
2 users	rating	mismatch	1
3 user_promo_codes	updated_at	mismatch	8
4 user_promo_codes	bonus_rides	mismatch	27
5 user_promo_codes	_id	missing in source	3
6 orders	updated_at	mismatch	32
7 orders	status	mismatch	1
8 orders	radio	mismatch	0

Кросс-проверки Источник<->Приёмник

- Определить важные сущности и атрибуты для сверки
- Настроить альтернативную выгрузку
- Загрузить выборку в Хранилище
- Осуществить сверки с основными данными
- Визуализировать результаты
- Установить на регулярный запуск
- По сути – это контроль работы ваших ELT Pipelines

Уведомления

Wheely

Threads

All DMs

Mentions & reactions

Saved items

Slack Connect

More

Starred

analytics

analytics-devops

analytics-etl-notifications

analytics-hiring

analytics-team-only

proj-events-tracking

snowplow-chauffeur

Channels

chat-analytics-back

competitors

deploy-prod

feat-braze-looker-segments

general

growth

hiring

it

marketing

moscow

#analytics-etl-notifications

Add a topic

Saturday, March 27th

Invoke dbt with `dbt seed` (Success in 1 minute, 6 seconds)

Invoke dbt with `dbt run-operation create_udf` (Success in 32 seconds)

Invoke dbt with `dbt run --full-refresh --exclude orders_logs_flatten` (Error in 5 hours, 36 minutes)

Invoke dbt with `dbt snapshot` (Skipped in 0 minutes)

Invoke dbt with `dbt docs generate` (Success in 1 minute, 48 seconds)

Yesterday

dbt Cloud

Run #16633350 failed on Job "TEST - MARTS NIGHTLY"

Environment

Trigger

Wheely CI

Scheduled

Duration

51 minutes, 4 seconds

Open run in dbt Cloud

Clone Git Repository (Success in 0 minutes)

Create Profile from Connection Wheely Redshift (Success in 0 minutes)

Invoke dbt with `dbt deps` (Success in 2 seconds)

Invoke dbt with `dbt run-operation stage_external_sources --vars 'ext_full_refresh: true'` (Success in 37 seconds)

Invoke dbt with `dbt seed --full-refresh` (Success in 1 minute, 18 seconds)

Invoke dbt with `dbt run-operation create_udf` (Success in 44 seconds)

Invoke dbt with `dbt run --full-refresh` (Success in 41 minutes, 2 seconds)

Invoke dbt with `dbt test --schema` (Error in 6 minutes, 1 second)

Message #analytics-etl-notifications

OTUS | ОНЛАЙН ОБРАЗОВАНИЕ

Настройка уведомлений в slack

```
40  def failed_task_slack_notification(kwarg):
41      """Send failed task notification with context provided by operator."""
42      print(kwarg['ti'])
43      dag = kwarg['ti'].dag_id
44      run_id = kwarg['run_id']
45      task = kwarg['ti'].task_id
46      exec_date = kwarg['execution_date']
47      try_number = kwarg['ti'].try_number - 1
48      max_tries = kwarg['ti'].max_tries + 1
49      exception = kwarg['exception']
50      log_url = kwarg['ti'].log_url
51      # command = kwarg['ti'].command(),
52
53  message = (
54      f'DAG` {dag}`
55      f'\n`Run Id` {run_id}`
56      f'\n`Task` {task} `(try {try_number} of {max_tries})`_`
57      f'\n`Execution` {exec_date}`
58      f'\n``{exception}```
59      # f`Command` {command}\n`
60  )
```

Настройка уведомлений в slack

```
def slack_failure_notification(context):
    task_id = context.get("task_instance").task_id
    dag_id = context.get("task_instance").dag_id
    exec_date = context.get("execution_date")
    log_url = context.get("task_instance").log_url
    slack_msg = f"""
        :red_circle: Task Failed.
        *Task*: {task_id}
        *Dag*: {dag_id}
        *Execution Time*: {exec_date}
        *Log Url*: {log_url}
    """

    failed_alert = SlackWebhookOperator(
        task_id="slack_notification",
        http_conn_id="slack_webhook",
        message=slack_msg,
        channel="data_engineering",
        username="failbot",
    )

    return failed_alert.execute(context=context)

with DAG(
    "complex_snowflake_transform",
    description="Example DAG showcasing loading, transforming, and data quality checking with multiple datasets in Snowflake.",
    start_date=datetime(2021, 1, 1),
    schedule_interval=None,
    template_searchpath="/usr/local/airflow/include/sql/snowflake_examples/",
    catchup=False
) as dag:
```

Вопросы?



Ставим "+",
если вопросы есть



Ставим "-",
если вопросов нет

Реагирование

Процесс обработки ошибок

- Получить уведомление об ошибке
- Определить источник
- Собрать данные для исправления ошибки
- Прокоммуницировать со сторонами участниками
- Определить причину
- Внести исправления на своей стороне (если необходимо)
- Убедиться, что после исправления работает правильно
- Уведомить заказчика об исправлении

Вопросы?



Ставим "+",
если вопросы есть



Ставим "-",
если вопросов нет

Качество данных

Требования к большим данным:

- Актуальность
- Объективность
- Целостность
- Релевантность
- Совместимость
- Измеримость
- Управляемость
- Привязка к источнику данных
- Доверие к поставщику данных



Качество данных - это степень их пригодности к использованию

Список материалов для изучения

1. <https://docs.astronomer.io/learn/airflow-sql-data-quality>
2. [Implementing Data Quality Checks in Airflow and GreatExpectations](#)
3. <https://github.com/astronomer/airflow-data-quality-demo>
4. <https://habr.com/ru/articles/827136/>
5. <https://docs.getdbt.com/reference/data-test-configs>



Цели вебинара

Проверка достижения целей

1. Понять значение Data Quality в работе с данными
2. Разобраться с циклом работы DQ
3. Научиться определять и строить метрики качества данных
4. Узнать о способах мониторинга
5. Разобраться с процессом обработки ошибок

Рефлексия

**Заполните, пожалуйста,
опрос о занятии
по ссылке
<https://otus.ru/polls/126765/>**

Спасибо за внимание!